

Aby uruchomić model

Potrzeba mocy obliczeniowej:

1. HPC - praktycznie nielimitowany RAM, CPU, Dysk natomiast największym wąskim gardłem jest 5GB karty pamięci
2. Google Collab - 12.7 GB RAMu, 112 GB Dysku, GPU RAM 15GB <-- największy atut
3. Na ten moment najlepszym kandydatem wydaje się komputer w sali koła naukowego 8GB RTX, 32GB ramu. Największa zaleta to elastyczność

Wnioski:

1. HPC - Model Qwen 3B, nie dał rady zostać załadowany ze względu na ograniczoną liczbę pamięci karty graficznej (5GB)
2. Qwen 2.5 3B również nie dał rady się załadować ze względu na zbyt małą ilość ramu w darmowej wersji, natomiast model `moondream2`, który jest modelem najczęściej pobieranym według statystyk hugging face w tej kategorii uruchamia się bez problemu. Ograniczeniem modelu (ze względu na jego niewielką ilość parametrów 2B) jest podatność na halucynację, model został przetestowany na kilku zdjęciach takich jak:



Na co dał dosyć dokładny opis a nawet poprawnie odczytał rejestrację:

A sleek black Porsche Panamera is captured in the midst of a turn on a highway, positioned on the right side of the road and moving towards the left. The car's license plate reads "CVC-911". The backdrop features a dark, overcast sky, trees lining the roadside, and a concrete barrier along the right side of the highway. In the distance, structures that resemble industrial or warehouse-type buildings are visible. The road surface is asphalt and has a light-colored lane marking. The car is moving at a moderate speed, and there are no visible texts or other objects in the image besides the car, the road, and the surrounding environment.

Przetestowane również zostało inne zdjęcie z trudniejszą scenerią:



I zwraca taki opis:

A group of seven individuals are perched on a raised platform or embankment, overlooking the expanse of a breathtaking sunset over the ocean. They are all facing away from the camera, their arms casually draped around each other's backs, conveying a sense of camaraderie and shared experience. The sky is painted in a stunning gradient of orange and pink hues, reflecting off the relatively calm ocean surface. Mountains are visible in the distance on a horizon line. Several cable cars are visible in the distance, their cables stretching across the sky. The platform on which they are seated is white, providing a stark contrast to the vibrant colors of the sunset. The ocean stretches out behind them, meeting the sky at the horizon line.

Obecnie uważam że powinniśmy zostać przy modelu moondream2, który jest wystarczający do obecnych założeń a środowiskiem rozwojowym może być google collab, lub maszyna HPC, jeżeli otrzymalibyśmy dostęp do pamięci rzędu 16GB RAMU GPU do końca semestru, lub ukończenia projektu.

1. Odpowiedź na pytania dotyczące modeli VL (z założeń sprintu):

1. Jakie zwraca odpowiedzi - Dokładnie opisane wraz z wglądem w szczegóły
2. Jak zwraca odpowiedzi - Plain text

```
caption = model.caption(image5, length="normal")["caption"]
```

3. Jak elastyczny jest - Bardzo, na około przetestowanych 5-6 zdjęć dokładność była bardzo wysoka jak na tak niewielki model
4. Jeżeli jest to nisza to czy są datasey i demo fine tuningu - Okazuje się że nie jest to nisza a bardziej nowa gałąź LLMów, LLaVA jest jednym z grupy modeli LV - Language vision. Fine tuning opisany na stronie hugging face

```
https://huggingface.co/learn/cookbook/en/fine\_tuning\_vlm\_trl
```

5. Czy jest open source - Tak, Qwen VL jak i moondream2 sa open source
6. Jak dobrze dokumentacja jest poprowadzona - Bardzo dobrze, Qwen jak i moondream2 maja obszerna dokumentacje wraz z przykladami fine tuningu oraz przykladami uzycia

Kod na ten moment znajduje się na komputerze sali koła do prezentacji działania na zajęciach.

Kod 1:

Mozemy wgrać zdjęcie którego opis odstaniemy

Kod2:

Mozemy zrobić sobie zdjęcie i dostać opis

pomysl na rozwoj:

System na biezaco analizuje obraz z kamery, generujac w okreslonych odstepach czasu opis albo slowa klucz dla poszczegolnych klatek. Dzieki temu moglibysmy opisac jakis odcinek czasu, algorytm moze zinterpretowac kontekst i opisac zlozone zdarzenia dziejace sie przed obiektywem ktore bylyby ciezkie do sklasyfikowania.

Lub cos na zasadzie na podstawie zdjecia zdefiniowac czy na zdjeciu sa jakies obiekty niebezpieczne dla dzieci, takie zadanie gdyby bylo bazowane na klasyfikacji musielibysmy przygotowac model klasyfikacyjny na kazdy obiekt ktory moze byc niebezpieczny, tutaj mozna sprawdzic jak modele VLM poradza sobie z tym zadaniem.