

1. Jakie zwraca odpowiedzi?

- Opis zdjęcia: krótki albo szczegółowy (zależnie od promptu).
- Odpowiada na pytania typu “co jest na zdjęciu?”, “co robi osoba?”, “ile obiektów widać?”
- Rozumowanie na bazie obrazu: potrafi wyciągać wnioski i tłumaczyć krokami

2. Jak zwraca odpowiedzi?

- tekstowy output

3. Jak elastyczny jest ?

- Bardzo elastyczny - reaguje na instrukcje

4. Jeżeli jest to nisza to czy są datasety i demo fine tuningu

- To nie jest nisza. LLaVA jest przykładem nowej klasy modeli: multimodalnych LLM-ów / LMM (Large Multimodal Models), czyli “chatbotów”, które rozumieją obraz + tekst i odpowiadają tekstem, zależnie od instrukcji.

5. Czy jest open source?

- Tak

6. Jak dobrze dokumentacja jest poprowadzona?

- Dokumentacja jest wystarczająca i praktyczna do uruchomienia oraz fine-tuningu, ale bywa rozproszona między wersje (LLaVA / NeXT) i mniej wygodna na Windows