

Sprint T1 – Olaf Stokłos

1. Initial knowledge

LLaVA to model, który potrafi opisywać zdjęcia i odpowiadać na pytania dotyczące tego, co jest na obrazie. Dostaje zdjęcie jako input i zwraca tekstowy opis. Projekt jest open source i ma gotowe przykłady do uruchomienia.

2. Założenia

W sprincie chodziło o odpalenie gotowego kodu w Google Colab i sprawdzenie, jak model zachowuje się na różnych zdjęciach. Testy polegały głównie na wrzucaniu obrazów i patrzeniu, jakie odpowiedzi generuje model (I testowaniu różnych wariacji pytań typu takie które mogą znaleźć jakieś ograniczenia itp).

3. Cel

Celem projektu jest stworzenie prostego programu, do którego wrzucamy zdjęcie i dostajemy jego opis. W tym sprincie skupiliśmy się na zobaczeniu, co model potrafi i gdzie ma ograniczenia.

4. Jak działa model w praktyce

Na prostych zdjęciach model działa dobrze – poprawnie rozpoznaje główny obiekt i generuje sensowny opis. Odpowiedzi są długie, spójne i brzmią naturalnie. Model potrafi też odpowiadać na proste pytania, np. ile obiektów znajduje się na zdjęciu (Tylko do pewnego zakresu).

5. Halucynacje i ograniczenia

Przy pytaniach, na które nie da się odpowiedzieć na podstawie samego obrazu (np. co pies myśli), model często zaznacza brak pewności, ale mimo to przechodzi do zgadywania. Przypisuje emocje i intencje, których nie da się potwierdzić.

Nie jest to twarda halucynacja, ale raczej nadinterpretacja – model zamiast powiedzieć „nie wiem”, próbuje odpowiedzieć w sposób brzmiący naturalnie.

Główne ograniczenia:

- zgadywanie zamiast trzymania się faktów,
- brak jasnego rozróżnienia między pewną odpowiedzią a przypuszczeniem,
- słabsze działanie na trudniejszych lub abstrakcyjnych obrazach.

- brak wyizolowania przy liczeniu elementów/osób na zdjęciach gdzie jest ich duża ilość (tłum koncertu itp.)

6. Dataset i dokumentacja

Modele do opisywania obrazów nie są niszowe – istnieją do nich datasety i przykłady. LLaVA jest projektem open source i posiada dokumentację oraz demo.

7. Wnioski

Model dobrze sprawdza się na prostych przykładach i generuje naturalnie brzmiące opisy. Jego głównym problemem jest skłonność do zgadywania w sytuacjach, gdzie brakuje danych.

8. Pomysły na dalszy rozwój

- ograniczenie zgadywania w odpowiedziach,
- wyraźne zaznaczanie niepewności,
- rozszerzenie działania na wideo.